

赵一宁

大模型安全评测实习生

赵一宁 | 大模型安全评测实习生 | llm_safety@example.com | 北京 / 上海 / 深圳 / 远程 | 可连续实习 6 个月。关注可验证的 Agent workflow、检索增强生成、工具治理和工程落地，能够从需求澄清、原型实现推进到评测与运行观测。习惯把模糊需求拆成可检查的目标、证据和完成条件，并对模型输出保持可回溯的事实边界。

教育背景

浙江大学 软件工程硕士 2025.09-2028.06，GPA 3.88/4.00，研究方向为大模型应用工程与智能系统，参与可信生成与检索评测课题组。西安电子科技大学 计算机科学与技术学士 2021.09-2025.06，GPA 3.82/4.00，获优秀毕业设计。核心课程包括数据库系统、分布式系统、机器学习、自然语言处理、软件测试、计算机网络和人机交互；课程设计完成高并发任务队列与全文检索服务。

专业技能

技术栈：Python、Guardrails、Prompt Injection、pytest、LLM Judge。掌握 Agent 状态编排、Tool Calling、结构化输出、Checkpoint、人工审批和运行级 Trace；熟悉向量检索、BM25、Exact Match、Multi-query、RRF、Reranker 与引用校验；具备 FastAPI 接口开发、数据库建模、并发控制、故障注入、单元测试和离线评测经验。能够区分传输重试、结构修复和业务补偿，为工具定义输入输出合同、权限、超时、幂等策略与熔断边界；使用 Recall@K、MRR、nDCG、任务完成率、事实支持率、P95 延迟和 Token 成本评价系统。

实习经历

模拟云智实验室 | 大模型安全评测实习生 | 2026.03-2026.08。建立越权工具调用与事实幻觉的发布门禁。构造三百六十条提示词注入样例；将工具输入输出改为强类型合同，为外部动作增加审批、幂等键和审计记录；与产品、测试共同复盘十二类失败轨迹，将重复调用、证据不足和异常早停固化为回归样例。针对限流、连接中断和服务端错误实现有界指数退避，对参数错误和引用门控失败直接停止，避免多层重试放大调用量。建设运行看板，按模型路由、节点、成功状态统计延迟和 Token。模拟知识工程中心 | 研发实习生 | 2025.07-2025.12。负责文档接入、字段清洗、向量索引和质量看板，处理表格、双栏论文、扫描页和中英文混排材料；为每个结论保留来源页码与原文片段。发现先按关键词筛选再做向量召回会漏掉同义表达，改为语义候选与词法候选取并集，再统一重排。对无文字层、乱码文字层、重复页眉和跨页断句分别建立诊断信息，不让解析失败静默污染下游。

科研经历

围绕“建立越权工具调用与事实幻觉的发布门禁”开展小规模研究，比较单 Query、Multi-query 和查询改写在相同候选池中的差异；使用 Recall@K、MRR、nDCG、引用正确率与 P95 延迟评估，不以回答流畅度代替检索质量。设计困难负例，区分课程学习、计划尝试与真实交付，避免把未完成能力写成项目成果。进一步对 Chunk 长度、段落合并、跨页桥接和 Reranker 输入做消融，记录每次实验的数据版本、模型版本和阈值来源；当结果下降时逐例检查是抽取缺字、Query 偏移、召回遗漏还是重排反转。

项目经历

核心项目：建立越权工具调用与事实幻觉的发布门禁。高风险指令召回率达到 96.7%；系统记录 Query、候选 Chunk、重排分数、工具回执和最终引用，质量门控不通过时明确失败。针对长指令生成互补 Query，将地点和排除条件作为有原文证据的元数据约束，避免把现居地误当求职地点。运行回放控制台：从持久化 Checkpoint 重建最小状态，展示计划、工具调用、产物、异常和恢复位置；外发动作只允许在审批后执行一次。增加 stale run 扫描、心跳、业务产物幂等对账和历史 checkpoint 回溯，处理“业务写入成功但图状态尚未保存”的崩溃窗口。评测工具箱：覆盖中文、英文和混合语言样例，加入长文档、相似术语、无证据声明、Prompt Injection、循环调用与跨用户上下文污染等 Bad Case。分别报告 PDF 抽取、Chunk 召回、工具轨迹、任务终态、事实引用、延迟和成本，不用单一平均分掩盖关键失败。证据审查器：把模型给出的匹配项映射到 JD 和简历原文，要求关键结论具有双向引用；同一要求不能同时出现在匹配和缺口，替代条件满足后不再把其余选项误报为短板。

校园与开源

担任学院智能系统协会技术负责人，组织十二周 Agent 工程读书会和三次开源工作坊；维护一套简历 RAG 评测脚本，为新成员讲解检索、重排、证据门控和错误分析。参与开源项目 Issue 分类、测试补齐与文档审阅，能够写出可复现的错误步骤、期望行为和回归样例。获校级创新奖学金、软件设计竞赛二等奖，英语 CET-6；曾负责跨专业五人团队的迭代排期和技术评审。还负责整理需求变更、数据许可和模型版本，发布前逐项核对隐私脱敏、回滚预案与监控告警，并把线上反馈转化为可重复执行的验收场景。